

Modelado Estocástico

Clase 8

Prof. Fernando Grosz

fgrosz@udesa.edu.ar

Modelos VAR (*Vector Autoregressions*)

Hasta acá analizamos modelos autorregresivos univariados, como por ejemplo el proceso $AR(p)$. Ahora vamos a considerar un vector columna de k variables diferentes, por ejemplo, el vector $\mathbf{y}_t = (y_{1t} \ y_{2t} \ y_{3t} \ \dots \ y_{kt})'$ y queremos modelar este vector en términos de valores pasados del mismo. El resultado será un modelo de vectores autorregresivos o proceso VAR. Por ejemplo, un modelo $VAR(p)$ tiene la siguiente estructura:

$$\mathbf{y}_t = \mathbf{m} + \mathbf{A}_1\mathbf{y}_{t-1} + \mathbf{A}_2\mathbf{y}_{t-2} + \dots + \mathbf{A}_p\mathbf{y}_{t-p} + \boldsymbol{\varepsilon}_t$$

Cada A_i es una matriz de coeficientes de dimensión $k \times k$ y m es un vector de constantes de dimensión $k \times 1$, y ε_t es un vector de ruidos blanco que satisface que $E(\varepsilon_t) = \mathbf{0}$ para todo t y además,

$$E(\varepsilon_t \varepsilon_s') = \begin{cases} \mathbf{\Omega} & \text{si } t = s \\ \mathbf{0} & \text{si } t \neq s \end{cases}$$

donde $\mathbf{\Omega}$ es una matriz de varianzas covarianzas y se supone definida positiva. Los ε_t se suponen serialmente no correlacionados pero contemporáneamente pueden estar correlacionados.

Ejemplo: el caso más simple es cuando $k = 2$ y $p = 1$. Nos queda

$$\begin{aligned} \mathbf{y}_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} &= \begin{pmatrix} m_1 \\ m_2 \end{pmatrix} + \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} \\ &= \mathbf{m} + \mathbf{A} \mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t \end{aligned} \quad (*)$$

Se puede escribir explícitamente como:

$$y_{1t} = m_1 + a_{11}y_{1t-1} + a_{12}y_{2t-1} + \varepsilon_{1t}$$

$$y_{2t} = m_2 + a_{21}y_{1t-1} + a_{22}y_{2t-1} + \varepsilon_{2t}$$

Cada variable se expresa como una combinación lineal del rezago de sí misma y de los rezagos de las demás. Como uno puede esperarse del caso univariado, el comportamiento de $\mathbf{y}_t$ va a depender de la matriz $\mathbf{A}$. Sean los autovalores y autovectores de la matriz $\mathbf{A}$,

$$\mathbf{\Lambda} = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \quad \mathbf{C} = \begin{pmatrix} \vdots & \vdots \\ \mathbf{c}_1 & \mathbf{c}_2 \\ \vdots & \vdots \end{pmatrix}$$

Si los autovalores son distintos, entonces los autovectores $\mathbf{c}_1$ y $\mathbf{c}_2$ van a ser linealmente independientes y $\mathbf{C}$ va a ser no singular:

$$\mathbf{C}^{-1}\mathbf{A}\mathbf{C} = \mathbf{\Lambda} \quad \text{y} \quad \mathbf{A} = \mathbf{C}\mathbf{\Lambda}\mathbf{C}^{-1}$$

Definimos un nuevo vector de variables, $\mathbf{z}_t = \mathbf{C}^{-1}\mathbf{y}_t$ de modo que $\mathbf{y}_t = \mathbf{C}\mathbf{z}_t$. Multiplicando (*) por $\mathbf{C}^{-1}$ obtenemos que

$$\mathbf{C}^{-1}\mathbf{y}_t = \mathbf{C}^{-1}\mathbf{m} + \mathbf{C}^{-1}\mathbf{A}\mathbf{y}_{t-1} + \mathbf{C}^{-1}\boldsymbol{\varepsilon}_t$$

$$\mathbf{z}_t = \mathbf{m}^* + \mathbf{\Lambda}\mathbf{z}_{t-1} + \boldsymbol{\eta}_t$$

donde $\mathbf{m}^* = \mathbf{C}^{-1}\mathbf{m}$ y donde $\boldsymbol{\eta}_t = \mathbf{C}^{-1}\boldsymbol{\varepsilon}_t$ (vector de ruidos blanco). De modo que,

$$z_{1t} = m_1^* + \lambda_1 z_{1t-1} + \eta_{1t}$$

$$z_{2t} = m_2^* + \lambda_2 z_{2t-1} + \eta_{2t}$$

z_{1t} y z_{2t} son procesos AR(1) univariados y separados y van a ser $I(0)$ si el módulo de los autovalores λ_1 y λ_2 es menor a uno. Van a ser un *random walk* con *drift* cuando los autovalores sean iguales a uno y van a ser explosivos cuando los autovalores sean mayores a uno.

Este último caso vamos a descartarlo y vamos a concentrarnos en los otros dos.

Caso 1: $|\lambda_1| < 1$ y $|\lambda_2| < 1$. En este caso, los $\mathbf{z}_t$ son integrados de orden cero y como $\mathbf{y}_t = \mathbf{C}\mathbf{z}_t$, los $\mathbf{y}_t$ son una combinación lineal de los $\mathbf{z}_t$ y por lo tanto también van a ser $I(0)$. También se puede hablar de un equilibrio de largo plazo en este caso. Suponiendo que $\mathbf{y}_t$ toma un valor de largo plazo igual a $\bar{\mathbf{y}}$, de (*) obtenemos que tomando esperanza que

$$(\mathbf{I} - \mathbf{A}) \bar{\mathbf{y}} = \mathbf{m} \quad \text{o sea, } \mathbf{\Pi} \bar{\mathbf{y}} = \mathbf{m} \quad \text{donde } \mathbf{\Pi} = \mathbf{I} - \mathbf{A}$$

Va a haber una única solución para $\bar{\mathbf{y}}$ si la matriz $\mathbf{\Pi}$ es no singular.

Recordemos que:

- los autovalores μ_i de la matriz $\mathbf{\Pi}$ satisfacen que $\mu_i = 1 - \lambda_i$
- los autovectores de $\mathbf{\Pi}$ son iguales a los autovectores de A

De manera que si $\mathbf{\Pi}$ es no singular, la solución de $\bar{\mathbf{y}}$ es única y consecuentemente, los autovalores nos aseguran que las desviaciones del valor de largo plazo de $\bar{\mathbf{y}}$ serán transitorias y siempre se retornará a la media.

Caso 2: $\lambda_1 = 1$ y $|\lambda_2| < 1$. En este caso, z_{1t} es un *random walk* con *drift* y z_{2t} es $I(0)$. Entonces, como y_{1t} e y_{2t} son combinaciones lineales de los z_{1t} y z_{2t} tendremos que y_{1t} e y_{2t} serán ambos integrados de orden 1 ya que serán combinaciones lineales de un proceso $I(1)$ y de un $I(0)$. Por lo tanto, no va a tener sentido preguntarse si hay algún equilibrio estático de algún valor de $\bar{y}_1$ y de $\bar{y}_2$. Pero sí, va a tener sentido preguntarse si existe una relación de cointegración entre y_{1t} e y_{2t} .

La segunda fila de $\mathbf{z}_t = \mathbf{C}^{-1}\mathbf{y}_t$ nos queda $z_{2t} = \mathbf{c}^{(2)}\mathbf{y}_t$ donde $\mathbf{c}^{(2)}$ es la segunda fila de la matriz $\mathbf{C}^{-1}$. Lo interesante en este caso es que z_{2t} es una combinación lineal de dos variables $I(1)$ (que son y_{1t} y y_{2t}) pero z_{2t} es $I(0)$.

Para ver esto más explícitamente,

$$\mathbf{y}_t = \begin{bmatrix} \vdots \\ \mathbf{c}_1 \\ \vdots \end{bmatrix} z_{1t} + \begin{bmatrix} \vdots \\ \mathbf{c}_2 \\ \vdots \end{bmatrix} z_{2t}$$

Premultiplicando esta ecuación por el vector fila $\mathbf{c}^{(2)}$ nos queda

$$\mathbf{c}^{(2)} \mathbf{y}_t = z_{2t}$$

Por las propiedades de matrices no singulares: $\mathbf{c}^{(2)} \mathbf{c}_1 = 0$ y $\mathbf{c}^{(2)} \mathbf{c}_2 = 1$.

La relación de cointegración también puede escribirse en términos de la matriz Π . Tomando diferencias de:

$$\mathbf{y}_t = \mathbf{m} + \mathbf{A}\mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t$$

obtenemos

$$\Delta \mathbf{y}_t = \mathbf{m} - \Pi \mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t$$

Los autovalores de Π son 0 y $1 - \lambda_2$. Por lo tanto, Π es singular y tiene rango igual a uno. Como Π tiene los mismos autovectores que $\mathbf{A}$,

$$\mathbf{\Pi} = \mathbf{C} \begin{pmatrix} 0 & 0 \\ 0 & 1 - \lambda_2 \end{pmatrix} \mathbf{C}^{-1} = \begin{bmatrix} \vdots \\ \mathbf{c}_2(1 - \lambda_2) \\ \vdots \end{bmatrix} [\dots \quad \mathbf{c}^{(2)} \quad \dots]$$

O sea que a $\mathbf{\Pi}$, que tiene rango 1, la hemos factorizado en el producto de un vector columna por un vector fila. Esta factorización se llama “producto exterior” (“*outer product*” en inglés). El vector fila denota la relación de cointegración que recién vimos y el vector columna nos indica los pesos en la relación de cointegración. Es decir,

$$\Delta y_{1t} = m_1 - c_{21}(1 - \lambda_2)z_{2t-1} + \varepsilon_{1t}$$

$$\Delta y_{2t} = m_2 - c_{22}(1 - \lambda_2)z_{2t-1} + \varepsilon_{2t}$$

Esta última reformulación del VAR está expresada en términos de diferencias y niveles, donde todas estas son $I(0)$. Esta formulación suele llamarse “**Vector Error Correction**” (VEC), ya que z_{2t-1} mide en cuánto y_{1t} y y_{2t} se desvían de su relación de largo plazo.

Ejemplo (Caso 2): considere el sistema (hacemos $m_1 = m_2 = 0$)

$$y_{1t} = 1.2y_{1t-1} - 0.2y_{2t-1} + \varepsilon_{1t}$$

$$y_{2t} = 0.6y_{1t-1} + 0.4y_{2t-1} + \varepsilon_{2t}$$

Entonces, $A = \begin{pmatrix} 1.2 & -0.2 \\ 0.6 & 0.4 \end{pmatrix}$. Los autovalores de A satisfacen:

$$\det \begin{pmatrix} 1.2 - \lambda & -0.2 \\ 0.6 & 0.4 - \lambda \end{pmatrix} = 0. \text{ Resolviendo, } \lambda_1 = 1; \lambda_2 = 0.6$$

Para encontrar el autovector correspondiente a $\lambda_1 = 1$,

$$\begin{pmatrix} 1.2 - 1 & -0.2 \\ 0.6 & 0.4 - 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 0 \Rightarrow x_1 = x_2 \text{ o sea, } \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{ es un autovector asociado a } \lambda_1 = 1$$

Para encontrar el autovector correspondiente a $\lambda_2 = 0.6$,

$$\begin{pmatrix} 1.2 - 0.6 & -0.2 \\ 0.6 & 0.4 - 0.6 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 0 \Rightarrow 0.6x_1 = 0.2x_2 \text{ o sea, } \begin{pmatrix} 1 \\ 3 \end{pmatrix} \text{ es autovector correspondiente a } \lambda_2 = 0.6$$

De modo que $C = \begin{pmatrix} 1 & 1 \\ 1 & 3 \end{pmatrix}$ y $C^{-1} = \begin{pmatrix} 1.5 & -0.5 \\ -0.5 & 0.5 \end{pmatrix}$

Entonces, la expresión anterior,

$$\Delta y_{1t} = m_1 - c_{21}(1 - \lambda_2)z_{2t-1} + \varepsilon_{1t}$$

$$\Delta y_{2t} = m_2 - c_{22}(1 - \lambda_2)z_{2t-1} + \varepsilon_{2t}$$

nos queda en este ejemplo ($m_1 = m_2 = 0$):

$$\Delta y_{1t} = 0.2y_{1t-1} - 0.2y_{2t-1} + \varepsilon_{1t}$$

$$\Delta y_{2t} = 0.6y_{1t-1} - 0.6y_{2t-1} + \varepsilon_{2t}$$

O,

$$\Delta \mathbf{y}_t = - \begin{pmatrix} 0.4 \\ 1.2 \end{pmatrix} (-0.5 \quad 0.5) \mathbf{y}_{t-1} + \boldsymbol{\varepsilon}_t$$

Caso 3: $\lambda_1 = 1$ y $\lambda_2 = 1$. Este caso es diferente a los anteriores, porque ahora no van a haber dos autovectores linealmente independientes asociados a los autovalores repetidos. Por lo tanto, no va a existir la inversa de la matriz $\mathbf{C}$ que nos permitía diagonalizar la matriz $\mathbf{A}$.

Por ejemplo, si $\mathbf{A} = \begin{pmatrix} 0.8 & -0.4 \\ 0.1 & 1.2 \end{pmatrix}$. Se puede mostrar que los autovalores asociados serán $\lambda_1 = 1$ y $\lambda_2 = 1$ y el autovector asociado es $\begin{pmatrix} -2 \\ 1 \end{pmatrix}$. Pero nos va a faltar un segundo autovector.

Este caso puede analizarse usando matriz Jordan.

Si bien $\mathbf{A}$ no es diagonalizable, es posible encontrar una matriz no singular $\mathbf{P}$ tal que $\mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \mathbf{J}$, de modo que $\mathbf{A} = \mathbf{P}\mathbf{J}\mathbf{P}^{-1}$ donde $\mathbf{J} = \begin{pmatrix} \lambda & 1 \\ 0 & \lambda \end{pmatrix}$ es la matriz Jordan para el autovalor λ con multiplicidad 2. Sea $\mathbf{z}_t = \mathbf{P}^{-1}\mathbf{y}_t$ de manera que $\mathbf{y}_t = \mathbf{P}\mathbf{z}_t$.

Sustituyendo en (*) y simplificando, se obtiene que:

$$\mathbf{z}_t = \mathbf{J}\mathbf{z}_{t-1} + \mathbf{m}^* + \boldsymbol{\eta}_t$$

donde $\mathbf{m}^* = \mathbf{P}^{-1}\mathbf{m}$ y donde $\boldsymbol{\eta}_t = \mathbf{P}^{-1}\boldsymbol{\varepsilon}_t$ (vector de ruidos blanco). De modo que,

$$z_{1t} = \lambda z_{1t-1} + z_{2t-1} + m_1^* + \eta_{1t}$$

$$z_{2t} = \lambda z_{2t-1} + m_2^* + \eta_{2t}$$

Entonces, sustituyendo $\lambda = 1$,

$$(1 - L)z_{1t} = z_{2t-1} + m_1^* + \eta_{1t}$$

$$(1 - L)z_{2t} = m_2^* + \eta_{2t}$$

De modo que z_{2t} es $I(1)$ y multiplicando la primera por $(1 - L)$,

$$(1 - L)^2 z_{1t} = (1 - L)z_{2t-1} + (1 - L)\eta_{1t}$$

$$(1 - L)^2 z_{1t} = m_2^* + \eta_{2t} + \eta_{1t} - \eta_{1t-1}$$

Consecuentemente, z_{1t} es $I(2)$. Y por lo tanto, y_{1t} y y_{2t} son ambas $I(2)$.

Causalidad en el sentido de Granger (Granger causality): Decimos que x_t causa en el sentido de Granger a y_t si x_t y rezagos de x_t explican a y_t .

```
test_y2_to_y1 = results.test_causality(
    caused="y1",
    causing=["y2"],
    kind="f"
)
```

```
print(test_y2_to_y1.summary())
```

```
Granger causality F-test. H_0: y2 does not Granger-cause y1. Conclusion: reject H_0 at 5% significance level.
```

```
=====
Test statistic Critical value p-value    df
-----
          14.53           3.855   0.000 (1, 690)
-----
```

En este caso concluiríamos que con una probabilidad de error tipo I de 5%, rechazamos la hipótesis nula de que y2 no causa en el sentido de Granger a y1, o sea que encontramos evidencia estadística de que la variable y2 causa en el sentido de Granger a y1.

Vale la pena mencionar que causalidad en el sentido de Granger es un concepto estadístico.